Üretim Ekipmanlarında Arıza Durumu Sınıflandırması

AI4I 2020 üzerinde dengesiz sınıflandırma ve hata analizi

1. Problem ve amaç

Üretim ekiplerinin arıza içeren proses kayıtlarını ayırt etmesi, inceleme önceliği belirlemeye yardımcı olabilir. Bu çalışmada ürün türü, sıcaklık, devir, tork ve takım aşınması girdilerinden aynı kaydın arıza durumu sınıflandırılır. Hedef çıktı, Machine failure değişkeninin 0 veya 1 değeridir. Amaç bakım bağlamındaki bir sınıflandırma problemini çözmek ve kaçırılan arızaları incelemektir; gelecekteki arızaya kalan süre veya gerçekleşmiş tasarruf tahmin edilmez.

2. Veri kaynağı ve kapsam

UCI AI4I 2020 Predictive Maintenance veri seti [1], endüstriyel bakım senaryosunu temsil eden sentetik veridir. CSV 10.000 kayıt ve 14 sütun içerir. Hedefte 339 arıza (%3,39), 9.661 normal kayıt vardır. Eksik değer, tam satır kopyası ve tekrarlı UDI yoktur. Altı temel girdi üzerinde de tam özellik kopyası bulunmamıştır. Bu veri gerçek tesis ölçümü olarak sunulmamaktadır.

Modelde kullanılan temel veri	Tür / birim
Type (L, M, H)	Kategorik ürün kalite türü
Hava ve proses sıcaklığı	Sayısal / K
Dönüş hızı	Sayısal / rpm
Tork	Sayısal / Nm
Takım aşınması	Sayısal / dakika
Machine failure	Hedef / 0: normal, 1: arıza

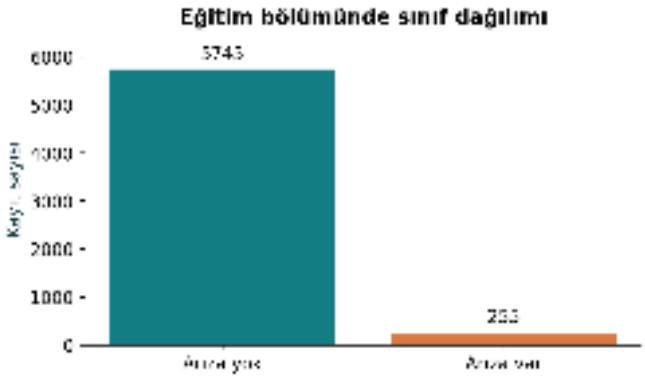
Deney bölmeleri

Bölüm / UDI aralığı	Kayıt	Arıza	Arıza oranı
Eğitim / 1-6000	6.000	255	%4,25
Doğrulama / 6001-8000	2.000	45	%2,25
Test / 8001-10000	2.000	39	%1,95

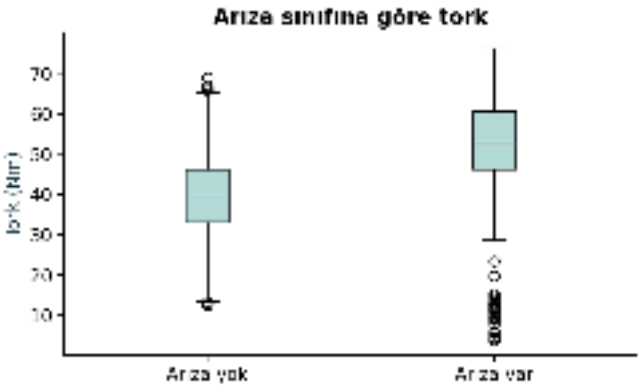
UDI sırası korunmuştur. UDI gerçek zaman damgası değildir; bu ayrım saha zaman serisi doğrulaması anlamına gelmez.

Veri keşfi

Üç inceleme yalnızca ilk 6.000 eğitim kaydını kullanır. Böylece keşif sırasında doğrulama ve test dağılımları model tasarımına taşınmaz.



Şekil 1. Eğitimde 5.745 normal ve 255 arızalı kayıt vardır. Bu dengesizlik, accuracy yanında arıza sınıfının recall ve F1 değerlerinin izlenmesini gerektirir.



Şekil 2. Arızalı grubun tork dağılımı daha yüksek değerlere uzanır; sınıflar belirgin biçimde örtüşür. Tork tek başına bütün arızaları ayıramaz.



Şekil 3. Küçük proses-hava sıcaklık farkı ve düşük devir bölgesinde bazı arızalar yoğunlaşır. Diğer bölgelerde de arıza vardır. Bu örüntü model için etkileşimli girdileri gerekçelendirir; grafik tek başına nedensellik kanıtlamaz.

Ön işleme ve model geliştirme

3. Sızıntıyı önleyen özellik hazırlığı

UDI ve Product ID kimlik alanlarıdır. TWF, HDF, PWF, OSF ve RNF arıza alt etiketleri sonuç bilgisi taşıdığı için modelden çıkarılmıştır. Beş sayısal girdi ve Type korunmuş, aynı kayıttaki girdilerden üç özellik türetilmiştir: sıcaklık farkı (proses - hava), mekanik güç (tork × rpm × 2π/60) ve aşınma × tork. Böylece toplam 9 girdi kullanılmıştır.

Eksik değer bulunmamasına rağmen medyan/mod doldurucuları Pipeline içinde tanımlıdır; yalnızca eğitimde öğrenilir. Type için OneHotEncoder, lojistik regresyonun sayısal girdileri için StandardScaler kullanılır. Random Forest ölçekleme gerektirmediği için ham sayısal değerleri alır. Ölçüm hatası kanıtı olmayan uç değerler korunur. Azınlık sınıfa class_weight ile ağırlık verilir; SMOTE uygulanmaz.

Veri kalite notu: 27 kayıtta ana hedef ile alt etiketlerin mantıksal birleşimi uyuşmaz (9 ana arıza etiketsiz, 18 ana normal kayıtta alt etiket var). Resmî ana hedef değiştirilmemiştir. Alt etiketler yalnızca hata analizinde kullanılmıştır.

4. Modeller ve temel hiperparametreler

Model	Seçim gerekçesi ve ayarlar
Çoğunluk tabanı	DummyClassifier, strategy=most_frequent. Her kayıt için normal sınıfını üretir.
Lojistik regresyon	Doğrusal başlangıç modeli. C=1, class_weight=balanced, max_iter=2000.
Random Forest	Doğrusal olmayan ilişkiler ve etkileşimler. 300 ağaç, min_samples_leaf=2, max_features=1.0, class_weight=balanced_subsample, max_depth=None.

5. Eğitim ve seçim yaklaşımı

Modeller ilk 6.000 kayıtta eğitilmiştir. Her öğrenen modelin karar eşiği, 2.000 doğrulama kaydında 0,05-0,95 arasında 0,01 adımla F1 en yüksek olacak biçimde seçilmiştir. Beraberlikte precision, ardından daha yüksek eşik tercih edilmiştir. Model seçimi de doğrulama F1 değerine dayanır. Sabit random_state=42 kullanılmış, geniş hiperparametre araması yapılmamıştır.

Doğrulama sonucu	Eşik	Precision	Recall	F1
Lojistik regresyon	0,86	0,3594	0,5111	0,4220
Random Forest	0,71	1,0000	0,7333	0,8462

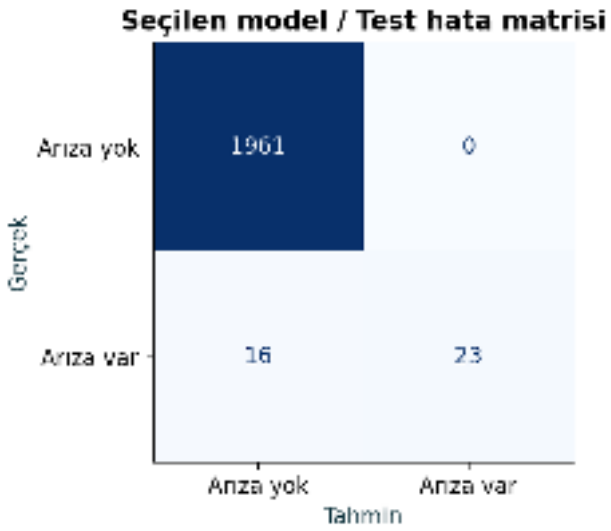
Random Forest seçildikten sonra model ve eşikler dondurulmuştur. Testte yeniden seçim veya eğitim yapılmamıştır. Tek doğrulama bölmesi kullanılması seçim belirsizliğinin bir sınırıdır.

Test sonuçları

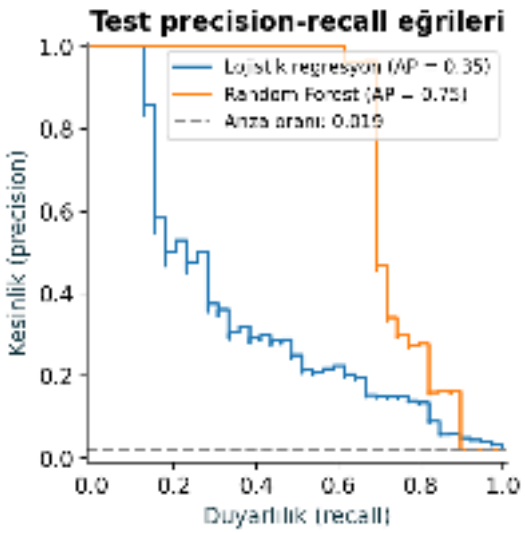
6. Sonuçlar, seçimde kullanılmayan son 2.000 kayıt üzerinde hesaplanmıştır. Pozitif sınıf arızadır. Accuracy bütün kayıtları, precision arıza denilen kayıtların isabetini, recall gerçek arızaların yakalanmasını, F1 ise precision-recall dengesini özetler.

Model	Accuracy	Precision	Recall	F1	AP
Çoğunluk	0,9805	0,0000	0,0000	0,0000	0,0195
Lojistik reg.	0,9800	0,4737	0,2308	0,3103	0,3519
Random Forest	0,9920	1,0000	0,5897	0,7419	0,7463

Seçilen model, 39 arızanın 23'ünü yakalamış, 16'sını kaçırmıştır. Testte yanlış alarm üretmemiştir. %99,20 accuracy yüksek görünse de arızaların %41,03'ü kaçmıştır. %98,05 accuracy alan çoğunluk tabanı hiçbir arızayı bulamaz; bu nedenle accuracy tek başına yeterli değildir.



Şekil 4. Random Forest hata matrisi: TN=1.961, FP=0, FN=16, TP=23. Satırlar gerçek, sütunlar tahmin sınıfıdır.



Şekil 5. Precision-recall eğrileri. AP, eğrinin average precision özetidir. Kesikli çizgi testteki arıza oranıdır (%1,95).

Eşik seçiminin yorumu

Doğrulamada F1 ile seçilen 0,71 eşiği, testte az sayıda ama isabetli arıza uyarısı üretmiştir. Gözlenen precision=1, yalnızca 23 pozitif tahmine dayanır ve gerçek tesiste sıfır yanlış alarm garantisi değildir. Çıktı puanları ayrıca kalibre edilmediği için gerçek saha arıza olasılığı gibi yorumlanmamalıdır.

Bir bakım uygulamasında daha yüksek recall gerekebilir. Bunun için kabul edilebilir kaçırma ve yanlış alarm maliyetleri önce tanımlanmalı, yeni doğrulama verisinde eşik seçilmelidir. Mevcut test sonuçlarına göre eşiği değiştirip aynı testi yeni başarı kanıtı olarak kullanmak uygun değildir.

Hata analizi, sonuç ve erişim

7. Hatalar nerede yoğunlaşıyor?

Arıza alt etiketi	Pozitif test kaydı	Kaçırılan
TWF / takım aşınması	10	9
PWF / güç	10	2
OSF / aşırı zorlanma	21	4
HDF / ısı dağılımı	0	Ölçülemez
RNF / rastgele arıza	0	Ölçülemez

Alt türler örtüşebilir; satır sayıları toplanarak ana arıza sayısı hesaplanmaz. TWF grubunda 9/10 kaçırma, aşınma kaynaklı arızaların belirgin bir zayıflık olduğunu gösterir. Örneğin UDI 8112'de aşınma 209 dakika, TWF=1, model puanı 0,0097'dir. Buna karşılık UDI 8027'de puan 0,5963 olup 0,71 eşiğinin altında kaldığı için arıza kaçırılmıştır. Hataların tamamı yalnızca eşik sınırında değildir.

8. Sonuç ve geliştirme önerileri

Random Forest, seçilen deneyde doğrusal modele göre daha iyi doğrulama F1'i ve test precision-recall dengesi sağlamıştır. Bununla birlikte testte yalnızca 39 arıza vardır ve recall %58,97'dir. Bölümler arasında arıza oranı %4,25'ten %1,95'e değişmektedir. Bu fark, veri dağılımının sabit olmadığını gösterir; performans değişiminin tek nedeni olduğunu kanıtlamaz.

Veri sentetik, arıza etiketleri kısmen kural tabanlıdır. Gerçek cihaz kimlikleri, kesin zaman damgaları ve arızaya kalan süre yoktur. Sonuçlar bir fabrikaya genellenemez ve erken uyarı süresi ölçülemez. Devam çalışmasında gerçek cihaz ve zaman ayrımlı dış doğrulama, takım değişimi geçmişi, maliyet temelli eşik ve yeni doğrulama üzerinde kararlılık analizi önerilir. Model bakım kararı yerine inceleme desteği olarak değerlendirilmelidir.

Kod erişimi ve tekrarlanabilirlik

Çalıştırılabilir Python defteri (GitHub bağlantısı)

Defter veriyi UCI'den indirir, SHA-256 doğrulaması yapar ve bütün sonuçları yeniden üretir. Ortam: Python 3.12.14, scikit-learn 1.8.0, pandas 2.2.3, NumPy 2.3.5. random_state=42. Kod, staj deposundaki arıza sınıflandırma klasöründedir.

Kaynaklar

[1] AI4I 2020 Predictive Maintenance Dataset. UCI (2020). CC BY 4.0. DOI: 10.24432/C5HS5C. Sentetik veri.

[2] scikit-learn: Common pitfalls and recommended practices; Tuning the decision threshold. Erişim: 17.10.2026.